

Deep GPVAR: Модернизация DeepAR для многомерного прогнозирования.

Цель работы

Разработка метода прогнозирования временных рядов, который позволяет учитывать корреляции между несколькими временными рядами. Для этого предлагается модернизировать алгоритм DeepAR, используя гауссовские процессы с переменной амплитудой (GPVAR).

Актуальность исследования

В современном мире, где данные играют все более важную роль в принятии бизнес-решений, прогнозирование становится ключевым инструментом для достижения успеха. Особенно в области финансов, планирования запасов и управления спросом, точные прогнозы имеют решающее значение для эффективной работы и максимизации выгод.

Одним из наиболее популярных подходов к прогнозированию временных рядов является использование глубоких нейронных сетей, таких как DeepAR. DeepAR был представлен компанией Amazon и стал основой для создания прогностических моделей, способных учитывать временные зависимости и сезонность в данных. Однако оригинальная модель DeepAR имеет ограничения, когда дело доходит до многомерного прогнозирования.

В свете этого, исследователи предложили новую модель, известную как Deep GPVAR (Deep Gaussian Process VAR), которая представляет собой модернизацию и расширение оригинального DeepAR для эффективного многомерного прогнозирования временных рядов. Deep GPVAR объединяет преимущества глубоких нейронных сетей и гауссовых процессов, чтобы достичь более точных и гибких прогнозов.

Модернизация DeerpAR с помощью гауссовских процессов

Гауссовские процессы (GP) - это статистические модели, которые могут моделировать неопределенность в данных и корреляцию между различными переменными. GP могут быть использованы для прогнозирования временных рядов и оценки неопределенности в прогнозах.

Модернизация DeerpAR с помощью GP может быть выполнена следующим образом:

1. Добавление GP в качестве компоненты неопределенности в DeerpAR. Это позволит моделировать неопределенность в прогнозах и учитывать ее при формировании прогнозов.

2. Использование GP для моделирования корреляции между различными временными рядами. Это позволит учитывать взаимосвязи между различными переменными и использовать эту информацию для более точного прогнозирования.

3. Использование GP для формирования априорного распределения параметров DeerpAR. Это позволит учитывать неопределенность в параметрах модели и использовать эту информацию для более точного прогнозирования.

Таким образом, модернизация DeerpAR с помощью GP может улучшить точность прогнозирования временных рядов и учитывать неопределенность в прогнозах.

Преимущества Deep GPVAR в многомерном прогнозировании

Deep GPVAR обладает несколькими преимуществами в многомерном прогнозировании:

- **Учет сложных временных зависимостей:** Deep GPVAR способен улавливать более сложные структуры данных, такие как тренды, сезонность и цикличность, что позволяет точнее прогнозировать многомерные временные ряды.
- **Оценка неопределенности прогнозов:** В отличие от оригинального DeepAR, Deep GPVAR позволяет оценить не только среднее значение будущих значений временных рядов, но и степень неопределенности или дисперсию прогнозов. Это предоставляет дополнительную информацию и уверенность при принятии решений на основе прогнозов.
- **Гибкость в моделировании различных сценариев:** Deep GPVAR позволяет моделировать различные сценарии и варианты развития временных рядов. Это особенно важно в сферах, где требуется учитывать возможные изменения и неопределенность, такие как финансовый рынок или планирование запасов.

Гауссовы связки в Deep GPVAR: Инновационный подход к многомерному прогнозированию

Гауссовы связки играют ключевую роль в моделировании зависимостей между переменными в Deep GPVAR. Они учитывают корреляцию между ошибками прогнозирования переменных, что особенно важно при прогнозировании многомерных временных рядов с сложной зависимой структурой.

Гауссовы связки в Deep GPVAR основаны на использовании многомерных гауссовых процессов. Пусть у нас есть вектор переменных

$$Y(t) = [y_1(t), y_2(t), \dots, y_n(t)]^t$$

где каждая переменная $y_i(t)$ представляет собой временной ряд. Мы можем описать гауссовую связку между этими переменными с помощью следующего уравнения:

$$Y(t) = X(t)\beta + H(t) + E(t)$$

где $X(t)$ - матрица регрессоров, β - вектор коэффициентов регрессии, $H(t)$ - многомерный гауссов процесс с нулевым средним и ковариационной матрицей Σ_H , $E(t)$ - многомерный гауссов шум с нулевым средним и ковариационной матрицей Σ_E .

Архитектура Deep GPVAR

Архитектура Deep GPVAR состоит из нескольких компонентов, которые работают совместно для прогнозирования многомерных временных рядов с использованием гауссовых связок. Вот основные компоненты:

1. Извлечение признаков

На первом этапе происходит извлечение признаков из исходных временных рядов. Это может быть выполнено с использованием различных архитектур нейронных сетей, таких как рекуррентные нейронные сети (RNN), сверточные нейронные сети (CNN) или их комбинаций. Извлечение признаков позволяет выделить информацию о долгосрочных зависимостях и закономерностях во временных рядах.

2. Гауссовы связки

После извлечения признаков происходит применение гауссовых связок для моделирования зависимостей между переменными. Гауссовы связки учитывают корреляцию между ошибками прогнозирования переменных и помогают моделировать их совместное распределение. Это достигается с помощью гауссовых процессов, которые моделируют условное среднее и ковариацию ошибок прогнозирования.

3. Генерация прогнозов

На последнем этапе происходит генерация прогнозов для каждой переменной. Это выполняется путем моделирования условного распределения переменных с использованием гауссовых связей и извлеченных признаков. Генерация прогнозов может быть осуществлена с использованием сэмплирования из условного распределения или с использованием других методов, таких как оптимизация или аппроксимация.

Ограничения Deep GPVAR

Несмотря на множество преимуществ, у Deep GPVAR также есть свои ограничения:

1. **Вычислительная сложность:** Deep GPVAR требует значительных вычислительных ресурсов для обучения и инференса. Обработка многомерных данных и гауссовских процессов может быть времязатратной операцией, особенно при использовании больших объемов данных.

2. **Необходимость большого объема данных:** для эффективного обучения Deep GPVAR требуется достаточное количество данных, особенно в случае многомерного прогнозирования. Недостаток данных или низкая частота наблюдений может снизить точность прогнозов.

Заключение

Deep GPVAR представляет собой модернизацию оригинальной модели DeepAR для многомерного прогнозирования временных рядов. Использование гауссовских процессов позволяет модели учитывать сложные временные зависимости и оценивать неопределенность прогнозов. Deep GPVAR имеет широкий спектр применений в различных отраслях.

Однако, необходимо учитывать вычислительные ограничения и необходимость большого объема данных для эффективного использования модели. Дальнейшее развитие Deep GPVAR и его адаптация к конкретным сценариям прогнозирования могут привести к еще более точным и гибким прогнозам в будущем.

Список литературы:

1. Salinas, D., et al. (2020). DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks. *Journal of Machine Learning Research*, 21(50),953-962.
2. Damianou, A., Lawrence, N. D. (2013). Deep Gaussian Processes. *Proceedings of the 16th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 207-215.
3. Flunkert, V., Salinas, D. (2018). DeepAR - Forecasting Seasonal Time Series with Autoregressive Recurrent Networks. *AWS AI Blog*. Retrieved from <https://aws.amazon.com/blogs/machine-learning/forecasting-seasonal-time-series-with-deepar/>
4. Rasmussen, C. E., Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. The MIT Press.
5. Salinas, D., Flunkert, V., Gasthaus, J. (2020). Modeling Uncertainty with Deep Gaussian Processes for Short-Term Load Forecasting. *arXiv preprint arXiv:2012.05811*.
6. Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., Scott, S. L. (2015). Inferring causal impact using Bayesian structural time-series models. *The Annals of Applied Statistics*, 9(1), 247-274.
7. Alvarez, M. A., Luengo, D., Lawrence, N. D. (2009). Latent Force Models. *Journal of Machine Learning Research*, 10, 411-436.
8. Barber, D. (2012). *Bayesian Reasoning and Machine Learning*. Cambridge University Press.
9. Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. The MIT Press.
10. Kingma, D. P., Welling, M. (2013). *Auto-Encoding Variational Bayes*.